단원 08

패키지 pydataset과 다양한 데이터 파일 활용

인공지능소프트웨어학과

강환수 교수

8.1 패키지 pydataset 활용

-

패키지 pydataset 개요

데이터셋(dataset)을 쉽게 메모리에 저장하고 활용할 수 있도록 제공되는 패키지

- **다양한 테스트용 데이터셋을 포함**
  - 데이터 분석이나 시각화 연습 등 다양한 용도로 활용
  - 이러한 데이터셋을 장난감 데이터(toy data)라고도 부름
- **pydataset의 주요 특징**
  - 다양한 데이터셋 제공
    - R 패키지인 datasets에 포함된 다양한 데이터셋을 파이썬에서 사용할 수 있도록 변환
    - 빠르게 샘플 데이터를 활용할 수 있음
  - 간편한 데이터 로드
    - 패키지를 설치하고 로드한 후, data() 함수를 사용하여 데이터셋을 쉽게 로드할 수 있음
  - 표준화된 데이터 포맷
    - 로드한 데이터셋은 판다스 데이터프레임 형태로 반환되어 데이터 분석 및 조작이 용이함

Pydataset 홈페이지

- **https://pydataset.readthedocs.io/en/latest/**

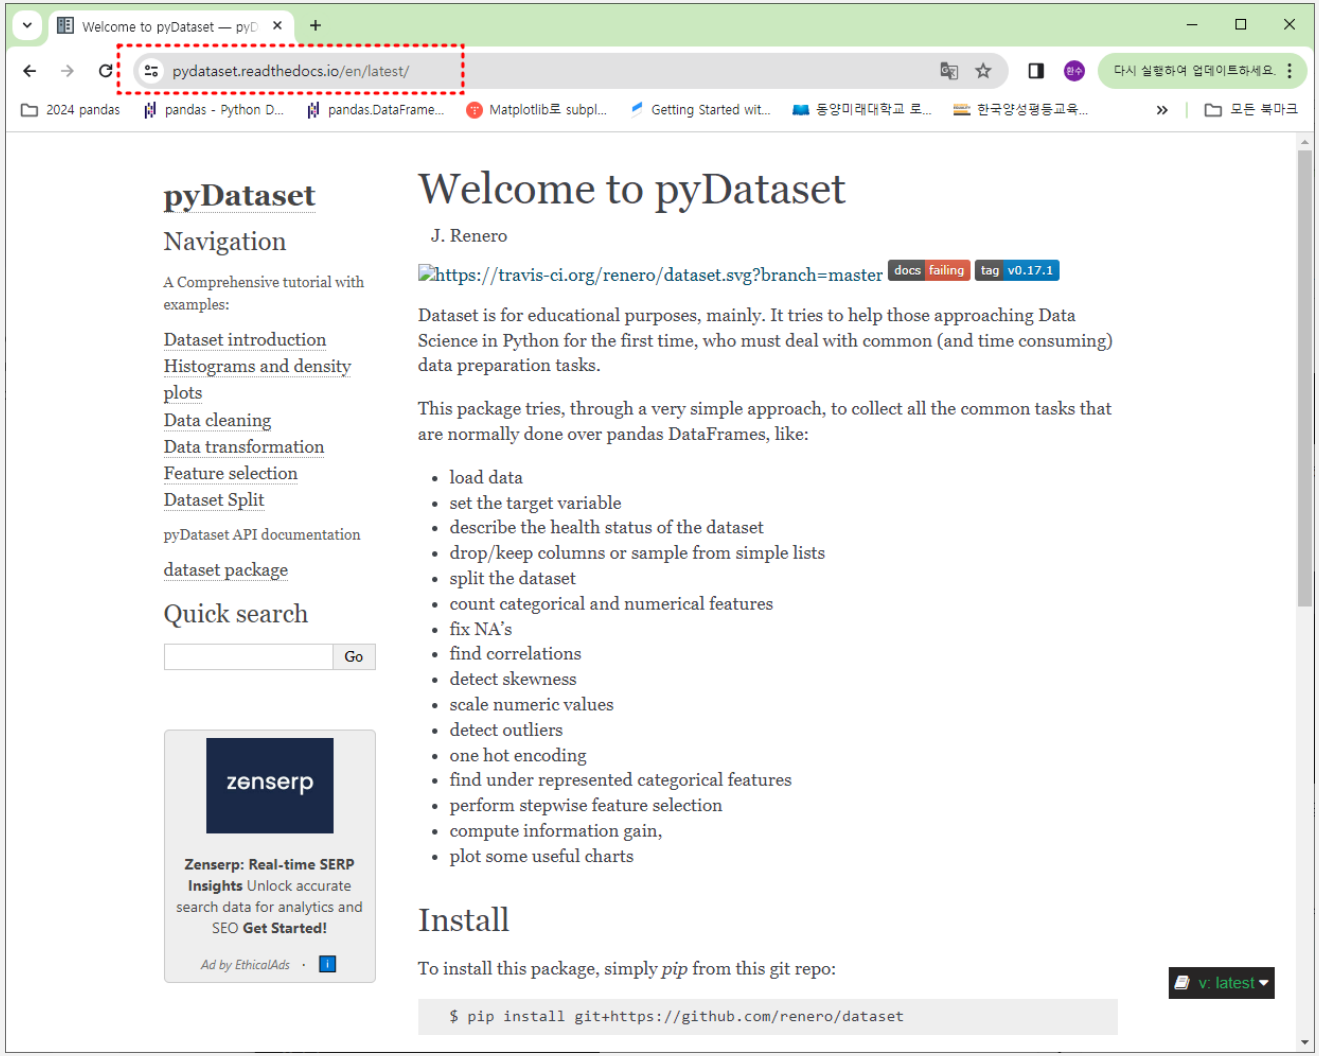

패키지 pydataset 설치

- **패키지 설치 명령 pip으로 pydataset을 간단하게 설치**
  - !pip install pydataset
- **이미 설치된 패키지 확인**
  - !pip show pydataset

```
!pip install pydataset
```
Python

```
Defaulting to user installation because normal site-packages is not writeable
Collecting pydataset
  Using cached pydataset-0.2.0.tar.gz (15.9 MB)
  Preparing metadata (setup.py): started
  Preparing metadata (setup.py): finished with status 'done'
Requirement already satisfied: pandas in d:\programdata\anaconda3\lib\site-packages (from pydataset) (1.
Requirement already satisfied: python-dateutil>=2.8.1 in c:\users\pc\appdata\roaming\python\python311\s:
Requirement already satisfied: pytz>=2020.1 in d:\programdata\anaconda3\lib\site-packages (from pandas-:
Requirement already satisfied: numpy>=1.21.0 in d:\programdata\anaconda3\lib\site-packages (from pandas-
Requirement already satisfied: six>=1.5 in c:\users\pc\appdata\roaming\python\python311\site-packages (f
Building wheels for collected packages: pydataset
  Building wheel for pydataset (setup.py): started
  Building wheel for pydataset (setup.py): finished with status 'done'
  Created wheel for pydataset: filename=pydataset-0.2.0-py3-none-any.whl size=15939425 sha256=020a24ce5f
  Stored in directory: c:\users\pc\appdata\local\pip\cache\wheels\29\93\3f\af54c413cecaac292940342c6188:
Successfully built pydataset
Installing collected packages: pydataset
Successfully installed pydataset-0.2.0
```

```
!pip show pydataset
```
✓ 9.0s Python

```
Name: pydataset
Version: 0.2.0
Summary: Provides instant access to many popular datasets right from Python (in dataframe structure).
Home-page: https://github.com/iamaziz/PyDataset
Author: Aziz Alto
Author-email: iamaziz.alto@gmail.com
License: MIT
Location: C:\Users\PC\AppData\Roaming\Python\Python312\site-packages
Requires: pandas
Required-by:
```

전체 자료 정보

설치된 pydataset의 전체적인 정보를 얻기 위해 데이터셋 목록을 표시

- **패키지 pydataset에서 데이터를 불러와 data()로 생성**
  - 데이터셋 ID(dataset_id))와 제목(title)이 포함된 데이터프레임을 반환
- **패키지 pydataset에는 757개의 샘플 데이터 제공**
  - from pydataset import data
  - all_data = data()
  - all_data

```
from pydataset import data

all_data = data()
all_data
```

✓ 0.2s

	dataset_id	title
0	AirPassengers	Monthly Airline Passenger Numbers 1949-1960
1	BJsales	Sales Data with Leading Indicator
2	BOD	Biochemical Oxygen Demand
3	Formaldehyde	Determination of Formaldehyde
4	HairEyeColor	Hair and Eye Color of Statistics Students
...	...	...
752	VerbAgg	Verbal Aggression item responses
753	cake	Breakage Angle of Chocolate Cakes
754	cbpp	Contagious bovine pleuropneumonia
755	grouseticks	Data on red grouse ticks from Elston et al. 2001
756	sleepstudy	Reaction times in a sleep deprivation study

757 rows × 2 columns

```
type(all_data)
```

```
pandas.core.frame.DataFrame
```

주요 자료 titanic 가져오기

- df = data('dataset_id', show_doc=True)
  - 데이터셋에 대한 간단한 설명만이 표시
    - 데이터에 대한 정보를 모를 때 편리하게 사용
- 타이타닉 데이터셋
  - 1912년 영국에서 미국으로의 첫 출항에 침몰한 타이타닉 배의 생존자와 사망자 정보 데이터셋
    - df = data('titanic', show_doc=True)
    - df

```
all_data[all_data.title.str.contains('titanic')]
```

	dataset_id	title
259	titanic	titanic
260	titanicgrp	titanicgrp

```
df = data('titanic', show_doc=True)
df
```

```
titanic

PyDataset Documentation (adopted from R Documentation. The displayed examples are in R)

## titanic

### Description

The data is an observation-based version of the 1912 Titanic passenger
survival log,

### Usage

    data(titanic)

### Format

A data frame with 1316 observations on the following 4 variables.

`class`

a factor with levels `1st class` `2nd class` `3rd class` `crew`

`age`
...
    glmlr <- glm(survival ~ age + sex + factor(class), family=binomial, data=titanic)
    summary(glmlr)
```

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

df = data('dataset_id')

- **df = data('titanic')**
  - 유명한 타이타닉 데이터셋을 가져오기

```
df = data('titanic')
df
```

✓ 0.0s

	class	age	sex	survived
1	1st class	adults	man	yes
2	1st class	adults	man	yes
3	1st class	adults	man	yes
4	1st class	adults	man	yes
5	1st class	adults	man	yes
...	...	...	...	...
1312	3rd class	child	women	no
1313	3rd class	child	women	no
1314	3rd class	child	women	no
1315	3rd class	child	women	no
1316	3rd class	child	women	no

1316 rows × 4 columns

```
df.info()
```

✓ 0.0s

```
<class 'pandas.core.frame.DataFrame'>
Index: 1316 entries, 1 to 1316
Data columns (total 4 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   class     1316 non-null   object
 1   age       1316 non-null   object
 2   sex       1316 non-null   object
 3   survived  1316 non-null   object
dtypes: object(4)
memory usage: 51.4+ KB
```

```
df.describe()
```

✓ 0.0s

	class	age	sex	survived
count	1316	1316	1316	1316
unique	3	2	2	2
top	3rd class	adults	man	no
freq	706	1207	869	817

자동차 연비 자료 mpg 가져오기

- **all_data[all_data.title.str.contains('car')]**
  - 데이터프레임 all_data에서 열 title에 문자열 'car'를 포함한 행 찾기
- **데이터셋 mpg(miles per gallon)**
  - 1999년과 2008년의 인기 차종 38개에 대한 연비 데이터

```
all_data[all_data.title.str.contains('car')]
```

✓ 0.2s

	dataset_id	title
382	mpg	Fuel economy data from 1999 and 2008 for 38 popular models of car

```
df_mpg = data('mpg')
df_mpg
```

✓ 0.0s

	manufacturer	model	displ	year	cyl	trans	drv	cty	hwy	fl	class
1	audi	a4	1.8	1999	4	auto(l5)	f	18	29	p	compact
2	audi	a4	1.8	1999	4	manual(m5)	f	21	29	p	compact
3	audi	a4	2.0	2008	4	manual(m6)	f	20	31	p	compact
4	audi	a4	2.0	2008	4	auto(av)	f	21	30	p	compact
5	audi	a4	2.8	1999	6	auto(l5)	f	16	26	p	compact
...	...	...	...	...	...	...	...	...	...	...	...
230	volkswagen	passat	2.0	2008	4	auto(s6)	f	19	28	p	midsize
231	volkswagen	passat	2.0	2008	4	manual(m6)	f	21	29	p	midsize
232	volkswagen	passat	2.8	1999	6	auto(l5)	f	16	26	p	midsize
233	volkswagen	passat	2.8	1999	6	manual(m5)	f	18	26	p	midsize
234	volkswagen	passat	3.6	2008	6	auto(s6)	f	17	26	p	midsize

234 rows × 11 columns

seaborn 설치

- 패키지 설치 명령 pip으로 seaborn을 간단하게 설치
  - !pip install seaborn

열 'manufacturer'인 자동차 생산 회사의 빈도수

- **sns.histplot(df_mpg['manufacturer’])**
  - 열 'manufacturer'인 자동차 생산 회사의 빈도수를 표시

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.histplot(df_mpg['manufacturer'])
plt.xticks(rotation=90)
plt.show()
```

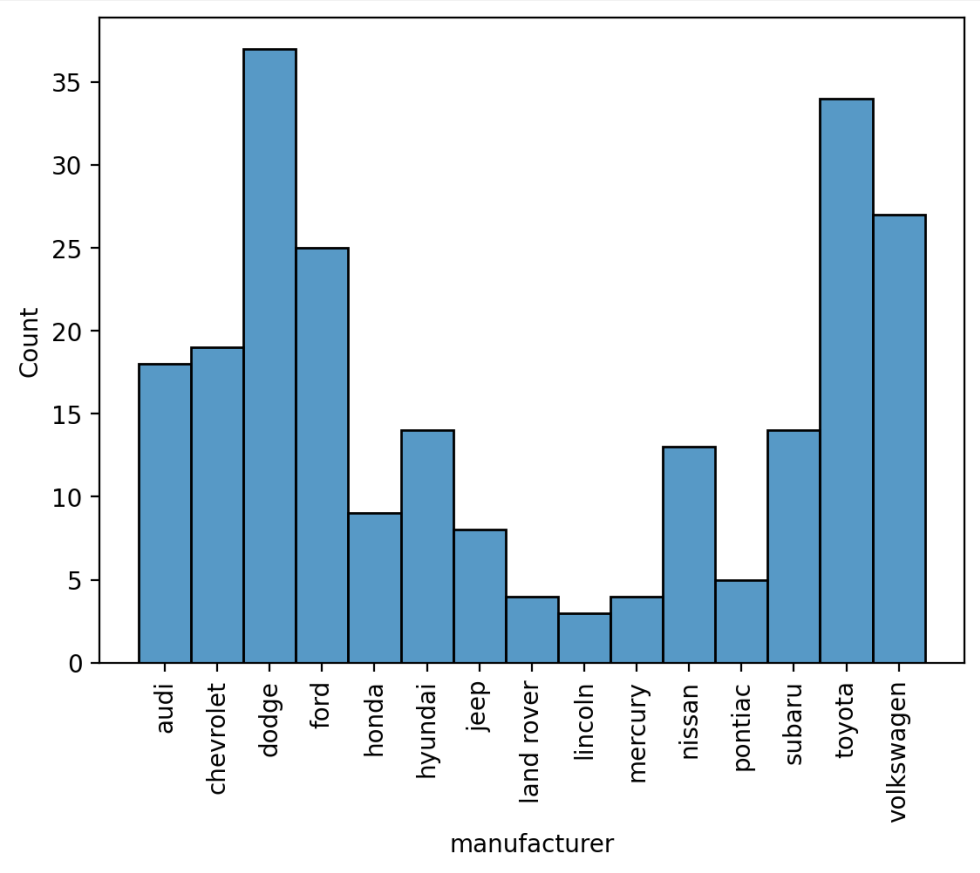

8.2 외부 파일 활용

-

다양한 파일 읽기

- **다양한 데이터 파일(csv, excel, sql, json, parquet 등)을 읽어오고 쓰는 방식을 제공**
  - 각 파일 형식에 맞는 접미사가 붙는 함수 read_*()와 to_*()를 제공
  - 함수 pd.read_excel()과 pd.to_excel()으로 간편히 엑셀 포멧 파일의 입출력이 가능
  - 다양한 형식 입출력 함수 제공(pandas.pydata.org 참조)

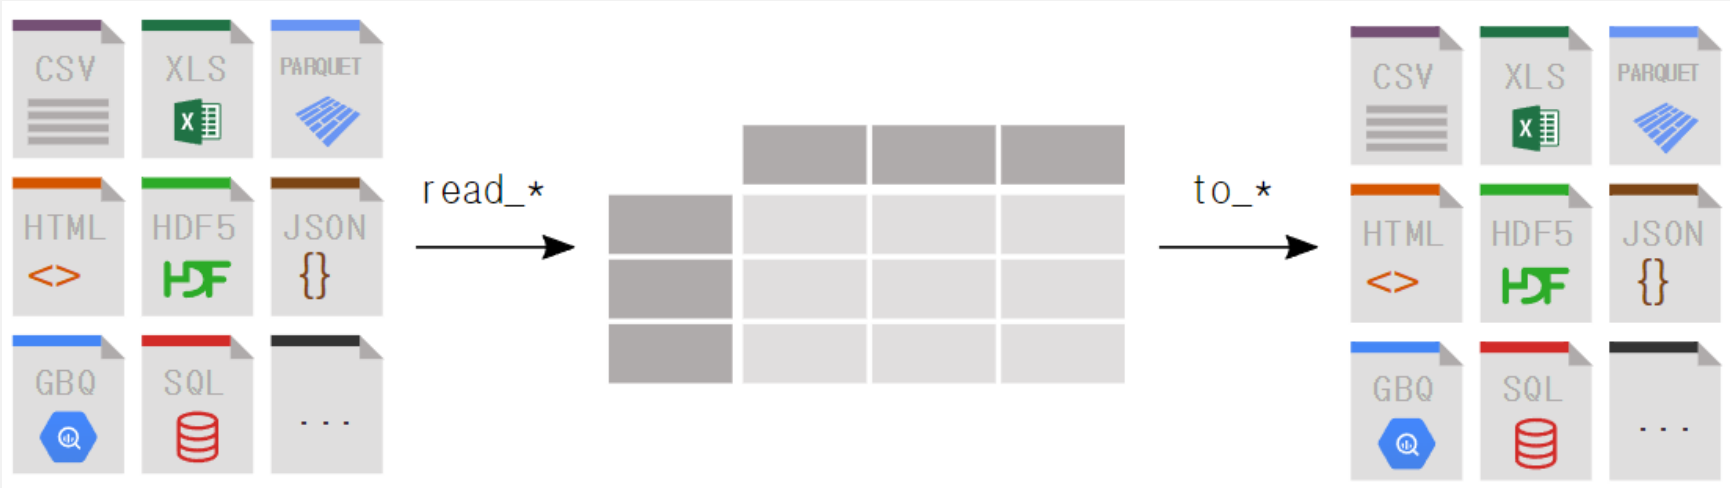

https://pandas.pydata.org/docs/getting_started/intro_tutorials/02_read_write.html

유명한 타이타닉 파일 읽기

- **read_excel()로 제공**
  - 판다스는 excel 파일로 저장된 데이터를 판다스의 데이터프레임으로 읽어오는 기능
  - 타이타닉 파일 titanic.xlsx을 읽어오기

```
import pandas as pd
titanic = pd.read_excel("titanic.xlsx", index_col=0)
titanic
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1304	3	0	Zabour, Miss. Hileni	female	14.5000	1	0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	3	0	Zabour, Miss. Thamine	female	NaN	1	0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	3	0	Zakarian, Mr. Mapriededer	male	26.5000	0	0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	3	0	Zakarian, Mr. Ortin	male	27.0000	0	0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	3	0	Zimmerman, Mr. Leo	male	29.0000	0	0	315082	7.8750	NaN	S	NaN	NaN	NaN

1309 rows × 14 columns

csv 파일로 쓰기와 읽기

- **to_csv() 함수로 작업하던 데이터프레임을 콤마로 자료를 구분하는 파일 titanic.csv에 저장**
  - 타이타닉 데이터프레임을 다시 CSV 파일로 저장하는 코드

```
titanic.to_csv("data/titanic.csv")
```

- **저장된 파일 titanic.csv에서 다시 read_csv() 함수로 읽어와 데이터프레임 tt에 저장**

```
tt = pd.read_csv("my_titanic.csv", index_col=0)
tt.head(8)
```

인터넷 자료의 파일 읽기와 쓰기

- **파일 '2022년도시도별교통사고.csv'**
  - 교통사고분석시스템 사이트인 https://taas.koroad.or.kr에서 내려 받기
  - 데이터프레임 traffic에 저장

```
import pandas as pd
traffic = pd.read_csv("data/2022년도시도별교통사고.csv", encoding='cp949')
traffic
```

	2022년도 시도별 교통사고	Unnamed: 1	Unnamed: 2	Unnamed: 3
0	시도	사고건수(건)	사망자수(명)	부상자수(명)
1	전국	196,836	2,735	281,803
2	서울	33,698	221	45,329
3	부산	10,882	113	14,829
4	경기	52,968	547	77,377
5	강원	6,425	139	10,160
6	충북	7,644	149	11,354
7	충남	8,164	230	11,964
8	전북	5,681	194	8,091
9	전남	8,335	201	12,611
10	경북	11,037	309	16,189
11	경남	10,611	258	14,545
12	제주	4,039	53	6,021
13	대구	11,102	68	15,721
14	인천	7,695	95	10,533
15	광주	7,122	58	10,722
16	대전	6,841	51	9,850
17	울산	3,660	32	5,177
18	세종	932	17	1,330

pd.read_csv(“file.csv", encoding='cp949', skiprows=1, index_col=0)

- **skiprows=1로 지정**
  - 위에서 첫 줄을 무시하고 읽으므로 정상적으로 열 명이 지정된 데이터프레임에 저장
- **index_col=0로 지정**
  - index 레이블이 기본 정수가 아닌 첫 열 ‘시도'를 index 레이블로 지정

```python
import pandas as pd

traffic = pd.read_csv("data/2022년도시도별교통사고.csv", encoding='cp949', skiprows=1, index_col=0)
traffic.head()
```

	사고건수(건)	사망자수(명)	부상자수(명)
시도			
전국	196,836	2,735	281,803
서울	33,698	221	45,329
부산	10,882	113	14,829
경기	52,968	547	77,377
강원	6,425	139	10,160

```python
traffic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 18 entries, 전국 to 세종
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   사고건수(건)  18 non-null     object
 1   사망자수(명)  18 non-null     object
 2   부상자수(명)  18 non-null     object
dtypes: object(3)
memory usage: 576.0+ bytes
```

traffic.info()

- 수에 콤마가 붙은 수를 정수로 인식하지 못함
- 문자열로 인식
  - 모든 열의 자료형이 object로 표시

```
traffic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 18 entries, 전국 to 세종
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   사고건수(건)  18 non-null     object
 1   사망자수(명)  18 non-null     object
 2   부상자수(명)  18 non-null     object
dtypes: object(3)
memory usage: 576.0+ bytes
```

정수로 읽기

thousands=','로 지정

- **간단히 콤마 ,가 붙은 자료를 수로 읽음**
  - 모든 열의 자료형이 int64

```python
import pandas as pd

traffic = pd.read_csv("data/2022년도시도별교통사고.csv", encoding='cp949', skiprows=1, index_col=0, thousands=',')
traffic.head()
```

	사고건수(건)	사망자수(명)	부상자수(명)
시도			
전국	196836	2735	281803
서울	33698	221	45329
부산	10882	113	14829
경기	52968	547	77377
강원	6425	139	10160

```python
traffic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 18 entries, 전국 to 세종
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   사고건수(건)  18 non-null     int64
 1   사망자수(명)  18 non-null     int64
 2   부상자수(명)  18 non-null     int64
dtypes: int64(3)
memory usage: 576.0+ bytes
```

패키지 seaborn을 활용 데이터 시각화

패키지 seaborn의 sns.barplot()을 사용해 세로 막대그래프

```
import seaborn as sns
import matplotlib.pyplot as plt
plt.rcParams['font.family'] = 'Malgun Gothic'
plt.rcParams['axes.unicode_minus'] = False
sns.barplot(traffic)
plt.show()
```

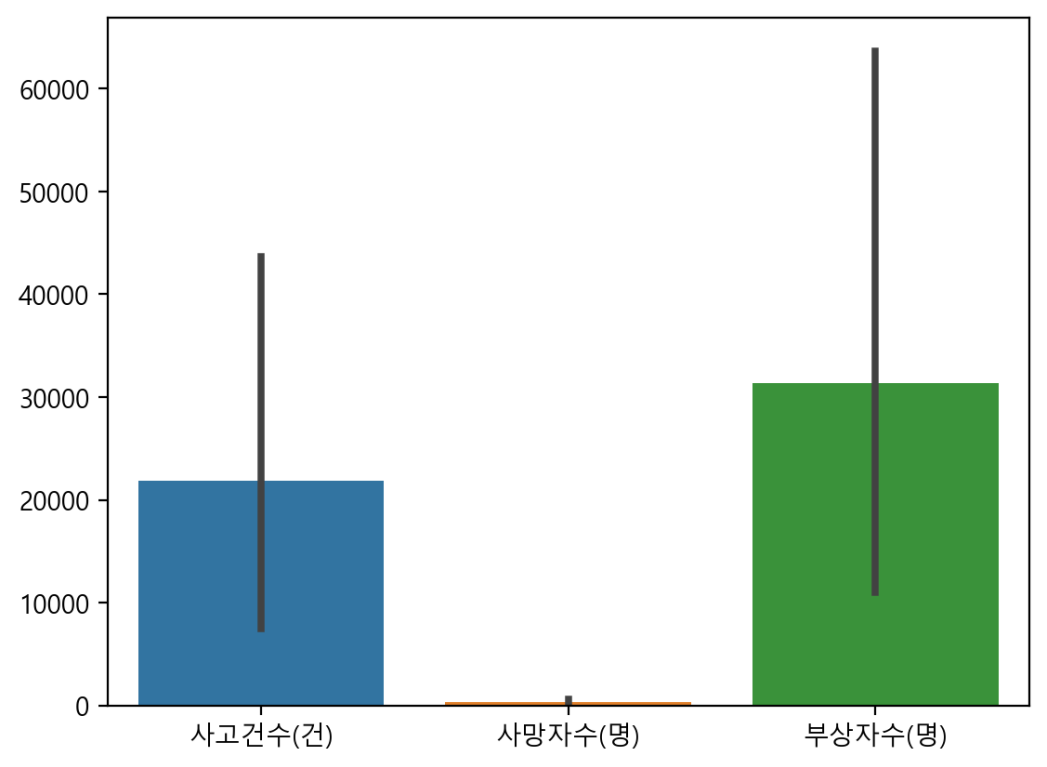

두 번째 열인 '사망자수(명)'를 시도 지역별로 막대그래프

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.barplot(traffic[['사망자수(명)']].T)
plt.show()
```

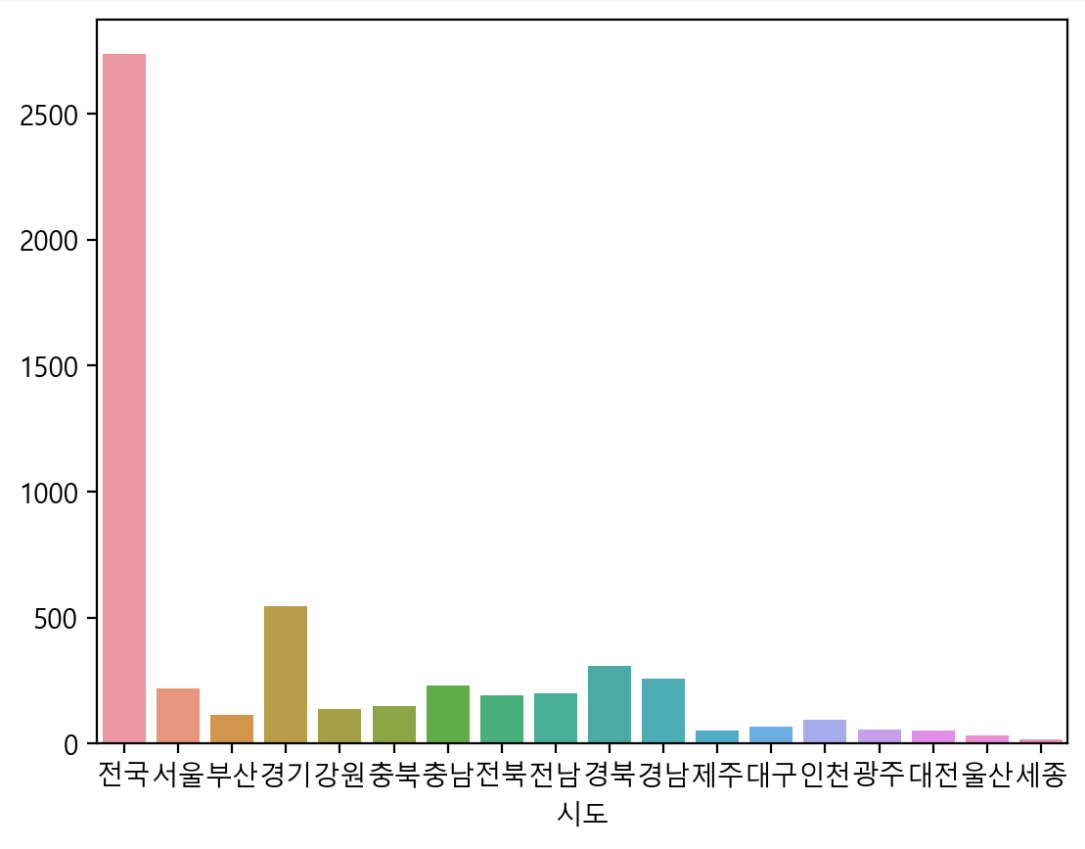

traffic.columns[2]: '부상자수(명)'

- 행과 열을 바꿔 첫 번째 열인 '부상자수(명)'을 시도 지역별로 막대그래프
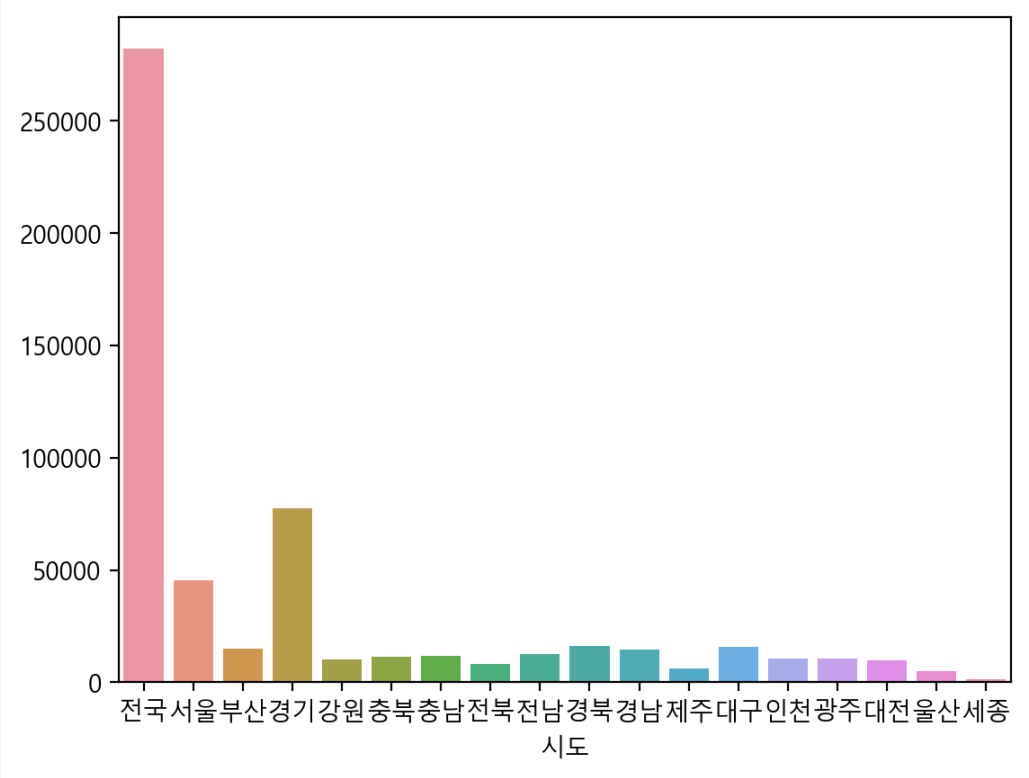
```
import seaborn ass ns
import matplotlib.pyplot as plt
sns.barplot(traffic[[traffic.columns[2]]].T)
plt.show()
```